



# Riesgos de extinción y vacíos de protección en las plantas y liquines de Colombia

Samuel Vanegas Suárez  
Juan Diego Vega Pongeuta  
Mariana Mancera Gómez  
Jerónimo Suárez Acosta



# PLANTEAMIENTO DEL PROBLEMA Y OBJETIVO

Colombia posee una gran diversidad de plantas y líquenes, pero no todas las especies cuentan con información suficiente sobre su estado de conservación. Existen diferencias entre las especies endémicas, las amenazadas y aquellas que tienen mecanismos de protección internacional.

Además, una parte importante de las especies todavía no ha sido evaluada, lo que dificulta identificar cuáles requieren atención prioritaria.

**Pregunta del proyecto:** ¿En qué grupos de plantas y líquenes se concentra el riesgo de extinción y cuáles presentan mayores vacíos de protección?

**Objetivo general:** Analizar la relación entre el riesgo de extinción, el endemismo, la forma de vida, la distribución geográfica y los mecanismos de protección para identificar los grupos más vulnerables.



# BÚSQUEDA Y OBTENCIÓN DE LOS DATOS

El proyecto utiliza el Catálogo de Plantas y Líquenes de Colombia, elaborado por el Instituto de Ciencias Naturales de la Universidad Nacional de Colombia y distribuido por SiB Colombia y GBIF.

## 01 Características de la fuente

Cobertura de información: 1951–2020.

Actualización del archivo: 11 de septiembre de 2023.

Licencia: Creative Commons BY 4.0.

Información taxonómica sobre plantas y líquenes registrados en Colombia.

## 03 Características del dataset

47.636 registros o nombres.

508 familias.

5.021 géneros.

10 regiones biogeográficas.

## 02 Justificación de la fuente

Se seleccionó esta fuente porque permite analizar la diversidad taxonómica del país y relacionarla con variables de conservación, endemismo, forma de vida, ubicación y amenaza.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")
plt.rcParams["figure.dpi"] = 110

RUTA = "catalogo_plantas_liquenes.csv"
SALIDA = "catalogo_plantas_liquenes_limpio.csv"
```



# COMPRENSIÓN DEL CONJUNTO DE DATOS

El catálogo es una lista de chequeo taxonómica. Esto significa que contiene información sobre nombres científicos y clasificación de especies, pero no es una base de datos de ocurrencias. Por lo tanto, no contiene necesariamente:

Coordenadas geográficas.

Fotografías.

Conteos de individuos.

Fechas específicas de colecta

## Hallazgo inicial

### Del total de registros:

29.917 corresponden a nombres aceptados.

17.719 corresponden a sinónimos.

Los sinónimos representan aproximadamente el 37,2 % del total.

| Variable             | Descripción                    |
|----------------------|--------------------------------|
| family               | Familia taxonómica             |
| genus                | Género de la especie           |
| scientific_name      | Nombre científico              |
| taxonomic_status     | Estado taxonómico              |
| life_form            | Forma de vida                  |
| establishment_means  | Condición de endemismo         |
| region_biogeografica | Región biogeográfica           |
| locality             | Ubicación registrada           |
| rango_altitudinal    | Rango de altitud               |
| threat_status        | Categoría de amenaza           |
| appendix_cites       | Protección internacional CITES |

```
print("Duplicados exactos:", df.duplicated().sum())
print("Celdas vacías:", f"{df.isna().sum().sum():,}", f"({df.isna().mean().mean():.1%})")

display(auditoria_calidad(df))
```

# Limpieza y preparación de datos

## Proceso realizado:

1. Carga y diagnóstico inicial.
2. Normalización de nombres de columnas.
3. Eliminación de duplicados.
4. Eliminación de columnas redundantes o constantes.
5. Limpieza y normalización de textos.
6. Unificación de categorías.
7. Conversión de altitudes a variables numéricas.
8. Tratamiento de valores faltantes.
9. Creación de variables derivadas.
10. Normalización y detección de valores atípicos.

```
columnas_antes = list(df_limpio.columns)
df_limpio.columns = [normalizar_nombre_columna(c) for c in df_limpio.columns]

renombres = {
    "rango_de_distribucion_altitudinal": "rango_altitudinal",
}
df_limpio = df_limpio.rename(columns=renombres)

print("Columnas antes:")
print(columnas_antes)
print("\nColumnas después:")
print(list(df_limpio.columns))
```

```
df_limpio = df.copy()
print("Copia creada: df_limpio")
```

```
filas_antes = len(df_limpio)
df_limpio = df_limpio.drop_duplicates().reset_index(drop=True)
print("Duplicados exactos eliminados:", filas_antes - len(df_limpio))

if "taxon_id" in df_limpio.columns:
    print("Duplicados por taxon_id:", df_limpio["taxon_id"].duplicated().sum())
```

# TRANSFORMACIÓN Y PREPARACIÓN DE VARIABLES



La variable rango\_altitudinal inicialmente estaba almacenada como texto. Para realizar análisis estadísticos fue necesario convertirla en variables numéricas.

## Variables creadas:

- ✓ altitud\_min: altitud mínima registrada.
- ✓ altitud\_max: altitud máxima registrada.
- ✓ altitud\_media: promedio entre la altitud mínima y máxima.
- ✓ amplitud\_altitudinal: diferencia entre la altitud máxima y mínima.

## Indicadores para identificar:

Si una especie es endémica.

Si una especie está amenazada.

Si el nombre corresponde a una especie aceptada.

Número de regiones donde aparece.

Número de formas de vida asociadas.

```
if "rango_altitudinal" in df_limpio.columns:
    extraido = df_limpio["rango_altitudinal"].astype("string").str.extract(
        r"(-?\d+(?:\.\d+)?)\s*-\s*(-?\d+(?:\.\d+)?)\s*msnm",
        expand=True
    )
    df_limpio["altitud_min"] = pd.to_numeric(extraido[0], errors="coerce")
    df_limpio["altitud_max"] = pd.to_numeric(extraido[1], errors="coerce")
    df_limpio = df_limpio.drop(columns=["rango_altitudinal"])
```

```
if "family" in df_limpio.columns:
    print("\nTop 10 familias:")
    display(df_limpio["family"].value_counts().head(10))


if "threat_status" in df_limpio.columns:
    print("\nEstado de amenaza:")
    display(df_limpio["threat_status"].value_counts(dropna=False))

if "es_endemica" in df_limpio.columns:
    print("\nEndemismo:")
    print(f"Endémicas: {df_limpio['es_endemica'].sum():,} "
          f"f"({df_limpio['es_endemica'].mean():.1%})")
```

# ANÁLISIS EXPLORATORIO DE DATOS — EDA

**Objetivo del EDA:** Comprender la estructura y distribución de los datos antes de realizar análisis más avanzados.

- Análisis realizados
- Distribución de la altitud media.
- Distribución de la amplitud altitudinal.
- Familias con mayor número de registros.
- Distribución de las categorías de amenaza.
- Proporción de especies endémicas.
- Relación entre variables numéricas.
- Identificación de valores atípicos.
- Visualizaciones utilizadas
- Histogramas.
- Gráficas de barras.
- Diagramas de caja o boxplots.
- Matrices de correlación.
- Interpretación general



El análisis exploratorio permitió observar que la mayoría de las especies se concentra en altitudes bajas y medias, aunque también existen especies con rangos altitudinales muy amplios.

# ANÁLISIS ESTADÍSTICO REALIZADO

**Se calcularon medidas como:** Media, Mediana, Desviación estándar, Mínimo, Máximo, Cuartiles.

## Resultados principales

| Variable             | Media   | Mediana |
|----------------------|---------|---------|
| Altitud mínima       | 1.001 m | 500 m   |
| Altitud máxima       | 1.787 m | 1.800 m |
| Altitud media        | 1.394 m | 1.200 m |
| Amplitud altitudinal | 786 m   | 500 m   |

## Otros análisis estadísticos

- Tablas de frecuencia.
- Comparación entre especies aceptadas y sinónimos.
- Comparación entre especies endémicas y no endémicas.
- Análisis de correlación.
- Detección de valores atípicos mediante el rango intercuartílico o IQR.
- Interpretación

La altitud media presenta una distribución sesgada hacia valores bajos. La mayoría de los registros se encuentra por debajo de los 1.500 metros, aunque existen especies que alcanzan altitudes cercanas a los 5.000 metros.

# HALLAZGO DE PATRONES, RELACIONES E INSIGHTS



## Principales patrones encontrados:

1. **Concentración del riesgo en los Andes:** La región Andina concentra una combinación importante de especies endémicas y amenazadas.

2. **Relación con la forma de vida:** Las palmas solitarias presentan una proporción de amenaza superior a la de los árboles.

 Palmas solitarias: 22,5 % amenazadas.

 Árboles: 2,9 % amenazados.

3. **Vacíos de evaluación:** El 92,4 % de las especies endémicas no cuenta con una evaluación de amenaza.

4. **Protección internacional insuficiente:** El 87,4 % de las especies clasificadas en peligro crítico no aparece en los apéndices CITES.

5. **Relación con la altitud:** El riesgo se concentra principalmente en especies ubicadas por encima de los 1.500 metros.

**Insight principal:** La riqueza de especies no necesariamente coincide con el nivel de conservación. Una región puede tener muchas especies, pero no necesariamente concentrar el mayor número de especies endémicas o amenazadas.

# SELECCIÓN DEL MODELO Y JUSTIFICACIÓN



## Modelo seleccionado

### Grafo de conocimiento en Neo4j


**¿Por qué se seleccionó?** El conjunto de datos contiene diferentes entidades y relaciones entre ellas:

Especies, Familias, Géneros, Regiones, Formas de vida, Categorías de amenaza, Apéndices CITES.

Estas relaciones pueden representarse de manera más clara mediante un grafo que mediante una tabla tradicional.

## Ventajas del modelo

- Representar relaciones entre entidades.
- Consultar información de manera flexible.
- Identificar grupos prioritarios.
- Analizar conexiones entre endemismo, amenaza y protección.



# APLICACIÓN DEL MODELO



## Proceso de aplicación:

- Se limpiaron y prepararon los datos.
- Se identificaron las entidades principales.
- Se definieron las relaciones entre especies y sus características.
- Se cargó la información en Neo4j.
- Se realizaron consultas para encontrar grupos prioritarios.
- Se evaluó el uso de un modelo local para transformar preguntas en español a consultas Cypher.

## Tecnologías utilizadas

- Neo4j 5.26.
- Python 3.12.
- Ollama.
- Qwen2.5-Coder 3B.

## Ejemplos de preguntas que permite responder

- ¿Qué especies amenazadas son endémicas de los Andes?
- ¿Qué familias concentran especies sin protección?
- ¿Qué especies en peligro crítico no tienen CITES?

# EVALUACIÓN DEL MODELO E INTERPRETACIÓN

## Evaluación del modelo

La evaluación se enfocó en comprobar si el modelo permitía:

- Representar correctamente las entidades y relaciones.
- Recuperar especies según filtros de conservación.
- Consultar información mediante Cypher.
- Identificar grupos prioritarios.
- Facilitar la interpretación de relaciones complejas.
- Interpretación de los resultados

El modelo de grafo permite conectar diferentes variables de conservación en una sola estructura. Esto facilita encontrar relaciones que pueden ser difíciles de observar utilizando únicamente tablas.

Por ejemplo, permite relacionar una especie con su familia, región, forma de vida, estado de amenaza y protección CITES.

**Resultado principal:** El grafo de conocimiento facilita el análisis de relaciones complejas y apoya la identificación de especies y grupos que requieren mayor atención para su conservación.

# CONCLUSIONES Y RECOMENDACIONES



## Conclusiones

- La limpieza de datos fue fundamental para evitar duplicados, errores de escritura y categorías inconsistentes.
- Los Andes concentran una combinación importante de endemismo y riesgo de extinción.
- Una gran proporción de especies endémicas todavía no ha sido evaluada.
- La protección CITES no cubre a muchas especies con alto riesgo de extinción.
- La forma de vida y la altitud ayudan a identificar grupos prioritarios.
- El grafo de conocimiento permite representar y consultar relaciones complejas entre las especies.

## Recomendaciones

- ✓ Priorizar evaluaciones de amenaza para especies endémicas no evaluadas.
- ✓ Fortalecer el monitoreo en regiones andinas.
- ✓ Revisar la protección de especies amenazadas que no cuentan con CITES.
- ✓ Mejorar la calidad y actualización de los registros taxonómicos.
- ✓ Integrar información de ocurrencia, coordenadas y abundancia en futuros estudios.

# REFERENCIAS



- Bernal, R., Gradstein, S. R. y Celis, M. (eds.). Catálogo de Plantas y Líquenes de Colombia. Darwin Core Archive v1.3. Instituto de Ciencias Naturales, Universidad Nacional de Colombia. Distribuido por el SiB Colombia. DOI: 10.15472/7avdhn. CC BY 4.0.
- Biodiversity Information Standards (TDWG). Darwin Core. <https://dwc.tdwg.org>
- UICN. Lista Roja de Especies Amenazadas. <https://www.iucnredlist.org>
- CITES. Apéndices I, II y III. <https://cites.org>
- Neo4j, Inc. Cypher Query Language Reference, v5.26. <https://neo4j.com/docs/cypher-manual/current/>
- Qwen Team, Alibaba Cloud. Qwen2.5-Coder Technical Report. <https://ollama.com/library/qwen2.5-coder>
- McKinney, W. pandas. <https://pandas.pydata.org>
- Hunter, J. D. matplotlib. <https://matplotlib.org>





**GRACIAS**